16.05.23

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

EINFÜHRUNG IN MASCHINELLES LERNEN

- Vorgehen zum Trainieren von maschinellen Lernalgorithmen
- Definition der linearen Regression
- Kostenfunktionen
- Optimierungsfunktionen

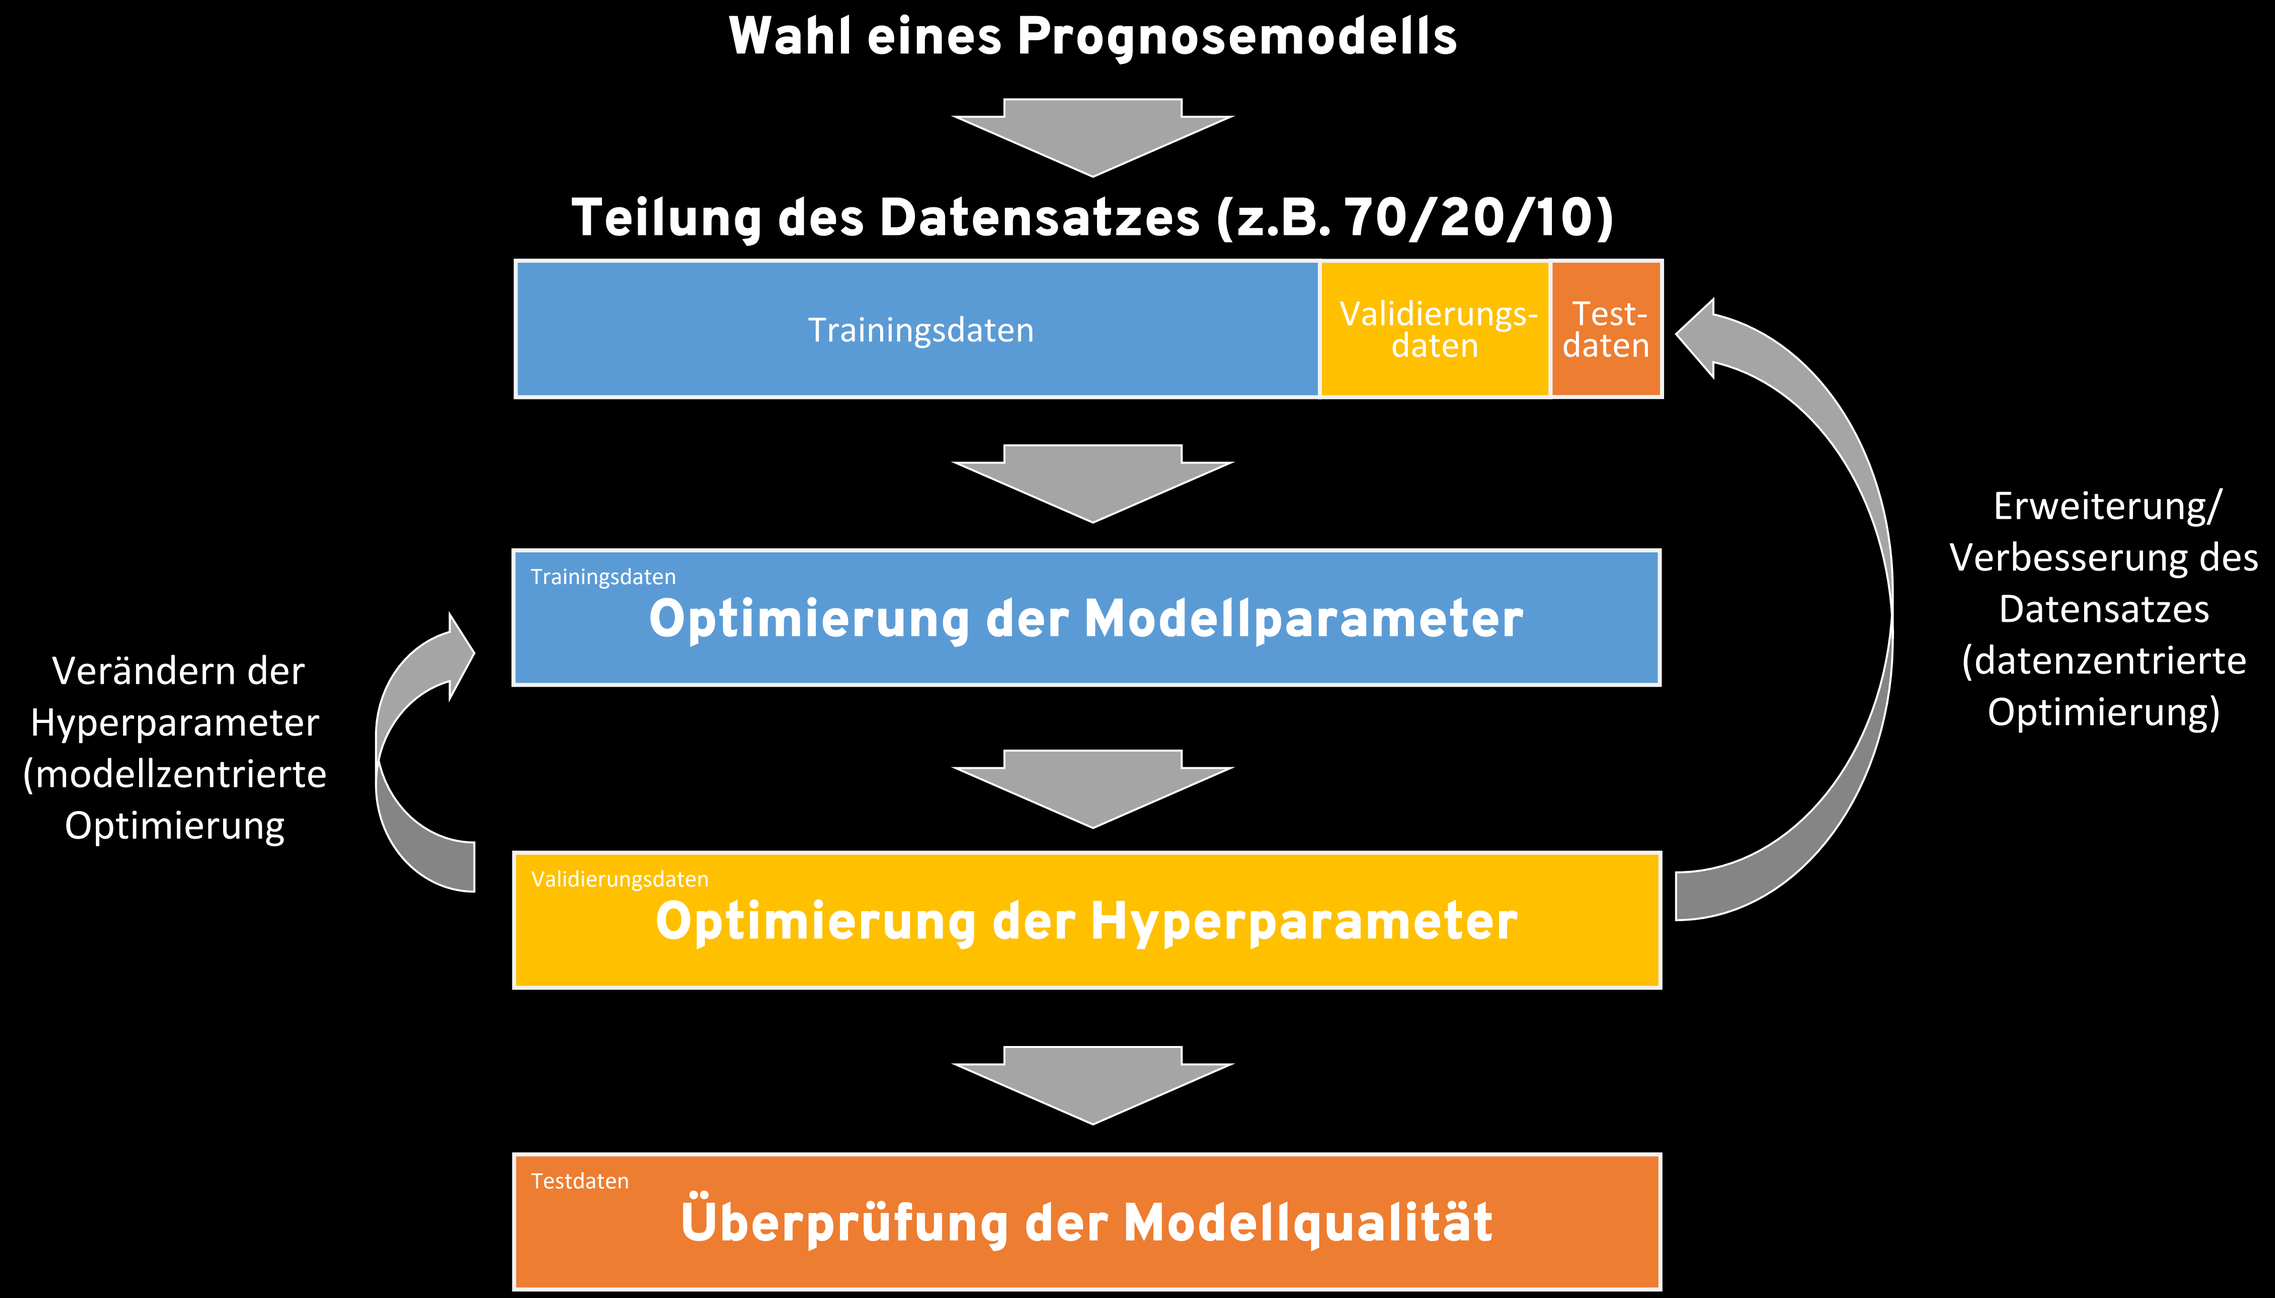
Wahl eines Prognosemodells
Teilung des Datensatzes (z.B. 70/20/10)
Trainingsdaten
Validierungs-daten
Test-daten
Trainingsdaten
Optimierung der Modellparameter
Validierungsdaten
Optimierung der Hyperparameter
Testdaten
Überprüfung der Modellqualität
Verändern der Hyperparameter (modellzentrierte Optimierung
Erweiterung/ Verbesserung des Datensatzes (datenzentrierte Optimierung)

TEILUNG EINES DATENSATZES (OHNE ZEITREIHEN!)

(1) Mischung der Reihenfolge (Randomisierung)

(2) Definition der Größen von Trainings-, Validierungs- und Testdatensatz in Prozent

(3) Teilung des Datensatzes

TEILUNG EINES DATENSATZES MIT ZEITREIHEN

(1) Ordnen der Zeitreihe

(2) Definition der Zeitreihenfenster für Validierungs- und Testdatensatz

(3) Teilung des Datensatzes

PROGNOSEMODELLE

In diesem Kurs behandelte:

- **Lineares Modell**
- **Neuronales Netz**
- **(Support Vektor Maschine)**

LINEARES MODELL

$$\hat{y} = \theta_0 + \theta_1 x$$

$$= h_x\,(\theta_0, \theta_1)$$

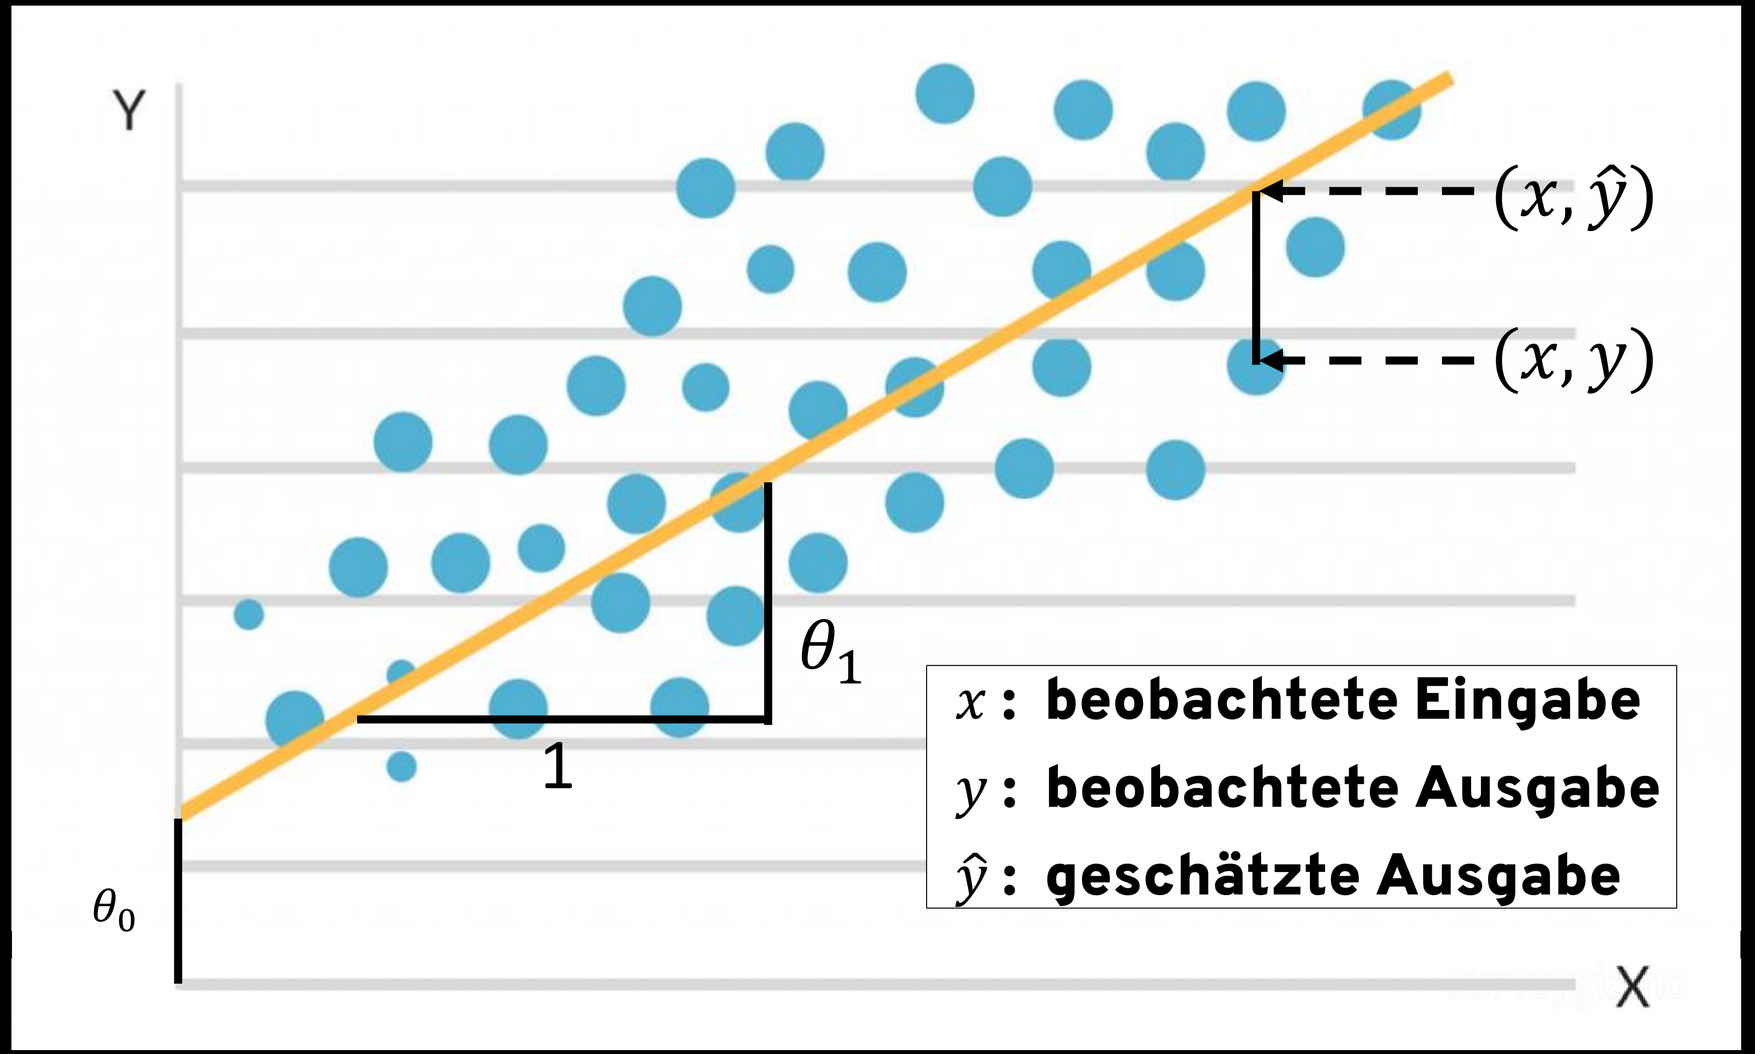

KOSTENFUNKTION

Zur Berechnung der Funktion mit den optimalen Parametern θ_0 und θ_1:

$$J_x(\theta_0, \theta_1) = \qquad h_x(\theta_0, \theta_1) - y$$

Mean Absolute Error (MAE)

$$J_x(\theta_0, \theta_1) = \frac{1}{m} \sum (h_x(\theta_0, \theta_1) - y)^2$$

Mean Squared Error (MSE)

MINIMIERUNG DER KOSTENFUNKTION

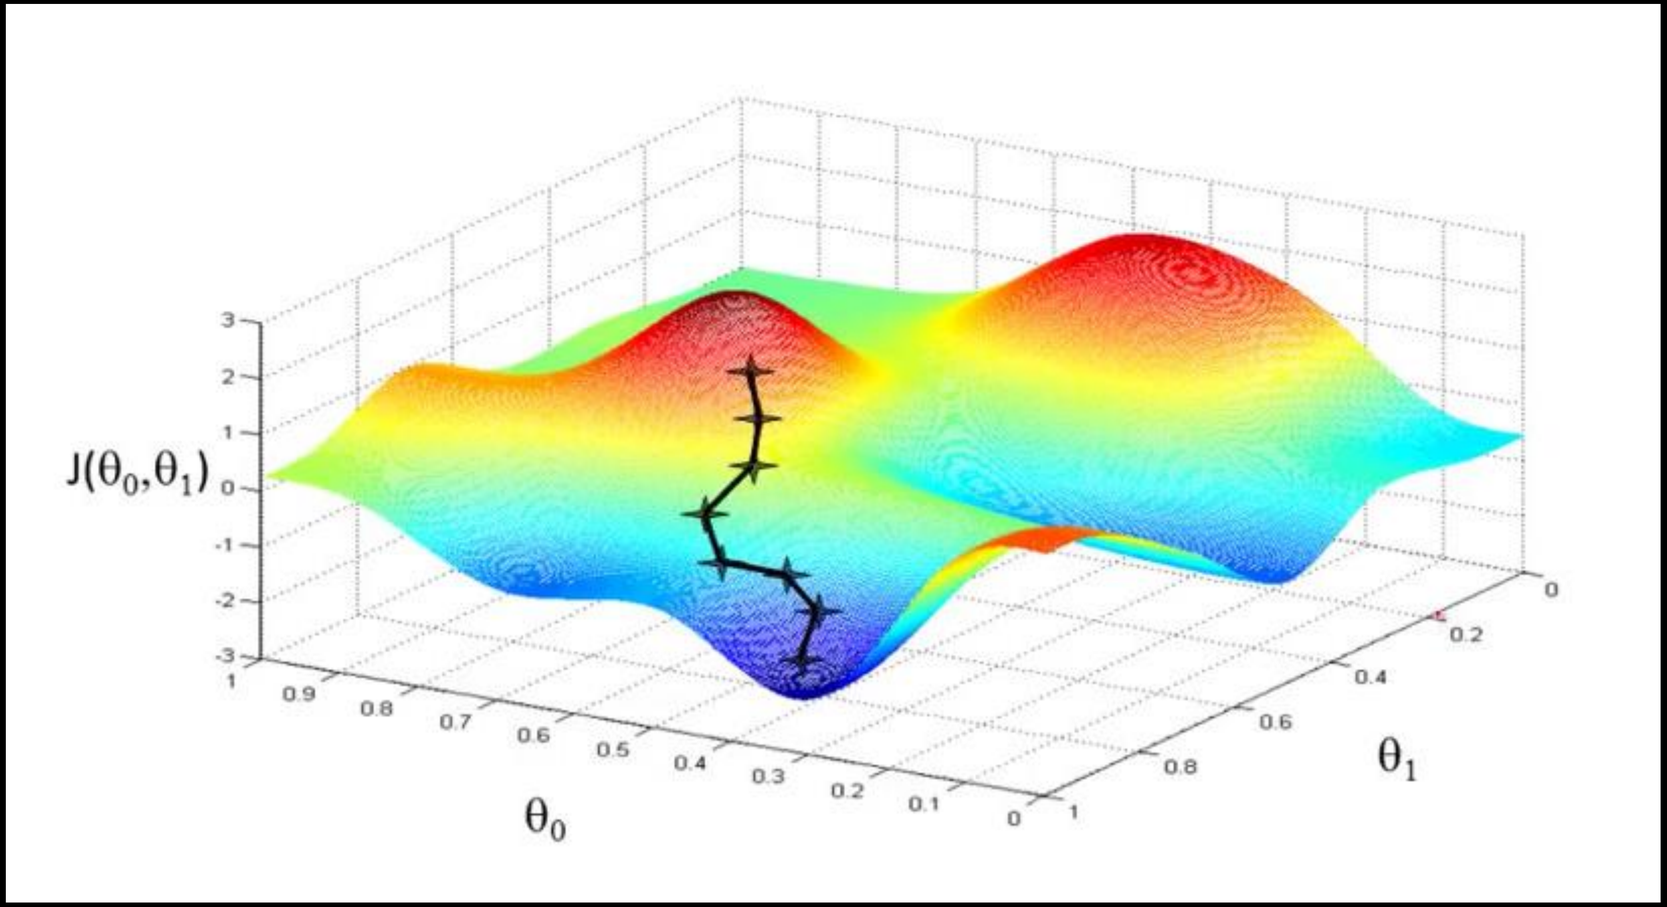

- **Über ein iteratives Verfahren (Gradient Descent), das sich dem Minimum annähert**
- **Schrittgröße zur Annäherung wird durch die Lernrate („Learning Parameter“) kontrolliert**

Quelle: https://www.coursera.org/learn/machine-learning

MINIMIERUNG BEI LINEAREN MODELLEN

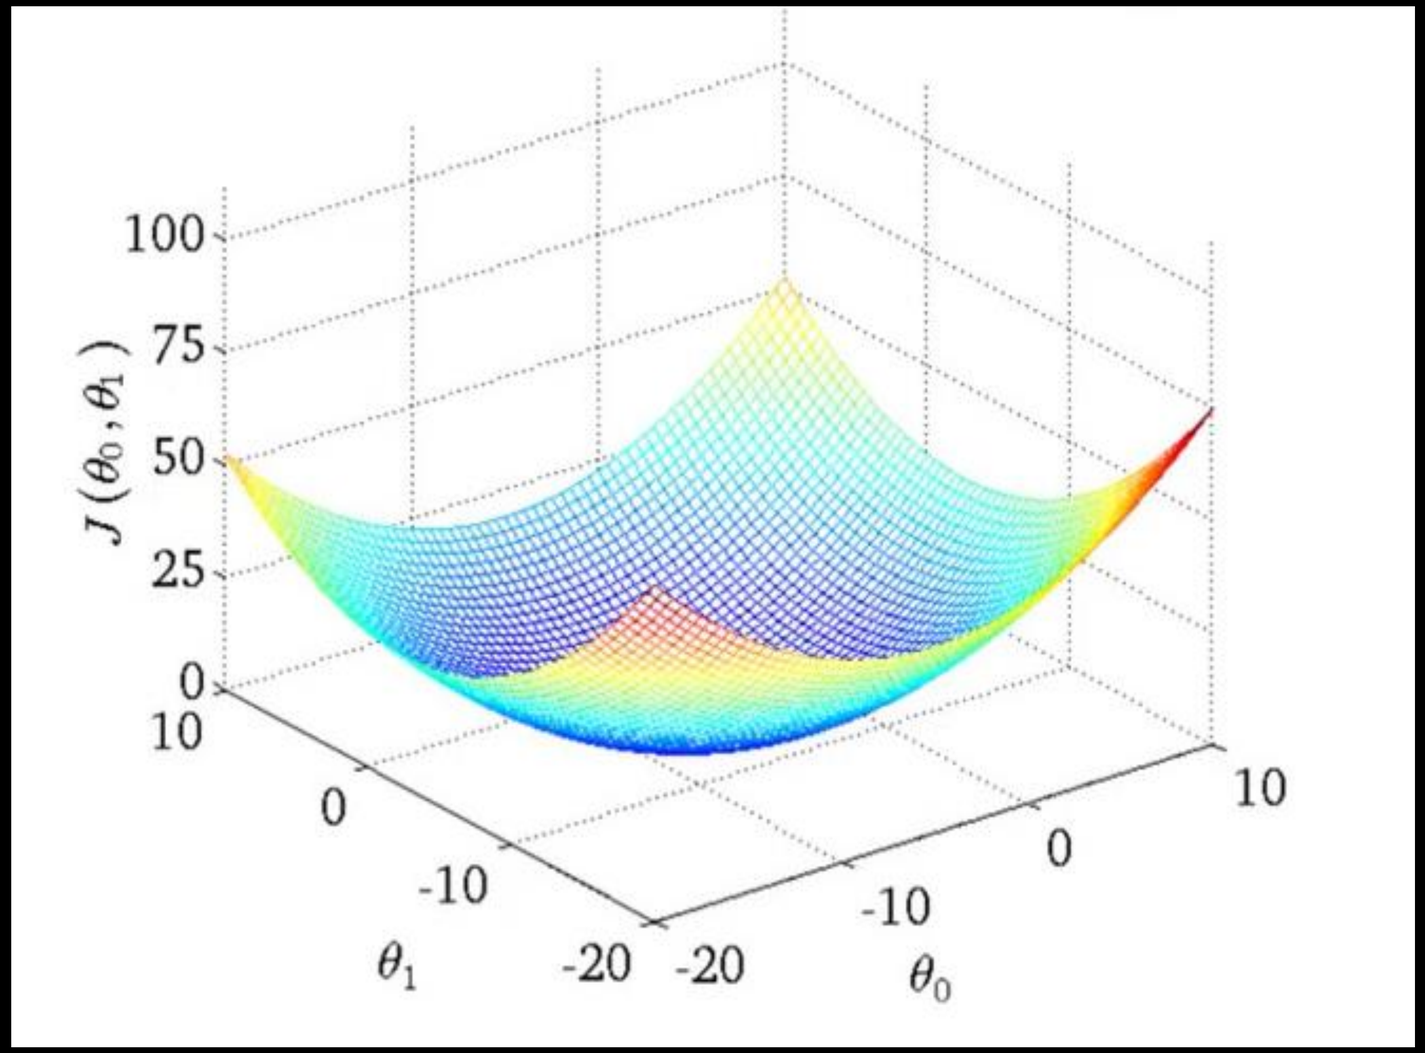

Quelle: https://www.coursera.org/learn/machine-learning

- **Für lineare Modelle ist die Kostenfunktion konvex und besitzt keine lokalen Minima.**
- **Hier werden häufig auch andere statistische Verfahren als Gradient Descent genutzt.**

  (Insbesondere wenn das Modell nur wenige Variablen umfasst.)

BEISPIEL EINES LINEAREN MODELLS

```
library(readr)
house_pricing <- read_csv("https://raw.githubusercontent.com/
                           opencampus-sh/einfuehrung-in-data-
                           science-und-ml/main/house_pricing_data/
                           house_pricing_train.csv")


mod <- lm(price ~ sqft_lot15 + as.factor(condition), house_pricing)
summary(mod)
```

ERGEBNIS DES LINEAREN MODELLS

```
Call:
lm(formula = price ~ sqft_lot15 + as.factor(condition), data = house_pricing)

Residuals:
    Min      1Q  Median      3Q     Max
-795388 -214555  -85989  101761 7183941

Coefficients:
                          Estimate Std. Error t value Pr(>|t|)
(Intercept)              3.261e+05  7.049e+04   4.625 3.77e-06 ***
sqft_lot15               1.138e+00  1.035e-01  11.002  < 2e-16 ***
as.factor(condition)2   -2.305e+04  7.690e+04  -0.300 0.764379
as.factor(condition)3    2.031e+05  7.057e+04   2.878 0.004008 **
as.factor(condition)4    1.800e+05  7.070e+04   2.546 0.010915 *
as.factor(condition)5    2.762e+05  7.118e+04   3.880 0.000105 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 366300 on 17284 degrees of freedom
Multiple R-squared:  0.01409,   Adjusted R-squared:  0.0138
F-statistic: 49.39 on 5 and 17284 DF,  p-value: < 2.2e-16
```

KENNWERTE DER REGRESSION

p-Wert

- **Signifikanzwert**
- **Wahrscheinlichkeit, dass der zugehörige Wert in der Regression gleich null ist.**
- **Werte unter 0,05 (entspricht 5%) werden üblicherweise als signifikant betrachtet**

(Adjustiertes) R^2

- **Kennzahl zur Beurteilung der Güte einer Regression**
- **Wert zwischen 0 und 1, der der dem Anteil der erklärten Variation entspricht (1 entspricht 100%):**

$$R^2 = \frac{\text{Erklärte Varianz}}{\text{Gesamtvarianz}}$$

- **Das adjustierte R^2 bestraft das Hinzufügen zusätzlicher Variablen/Parameter**

DataCamp Tutorial zur Linearen Modellierung in R :
https://www.datacamp.com/community/tutorials/linear-regression-R

BEISPIEL DATENSATZTEILUNG (KEINE ZEITREIHE)

````
#### Teilen des Datensatzen in Trainings- Validierungs- und Testdatensatz
```{r}
# Load the dplyr library
library(dplyr)

# Set a random seed for reproducibility
set.seed(42)
# Shuffle the data
data_shuffled <- data %>% sample_frac(1)

# Calculate the number of rows for each dataset
n_total <- nrow(data)
n_train <- floor(0.7 * n_total)
n_validation <- floor(0.20 * n_total)

# Split the data into training, validation, and test datasets
train_data <- data_shuffled %>% slice(1:n_train)
validation_data <- data_shuffled %>% slice((n_train + 1):(n_train + n_validation))
test_data <- data_shuffled %>% slice((n_train + n_validation + 1):n_total)

# Check the dimensions of the datasets
cat("Training dataset dimensions:", dim(train_data), "\n")
cat("Validation dataset dimensions:", dim(validation_data), "\n")
cat("Test dataset dimensions:", dim(test_data), "\n")

```
````

BEISPIEL LINEARE MODELLIERUNG UND VORHERSAGE

````
### Beispiel einer einfachen linearen Regression
```{r}
  mod <- lm(price ~ sqft_lot15 + as.factor(condition), train_data)
  summary(mod)

```

### Nutzung des resultierenden Modells für eine Vohersage
```{r}
# Make predictions using the test data
predicted_values <- predict(mod, newdata = validation_data)

# Compare the predicted values with the actual values
comparison <- data.frame(Actual = test_data$price, Predicted = predicted_values)

# Calculate the mean squared error (RMSE)
rmse <- sqrt(mean((comparison$Actual - comparison$Predicted)^2))

# Display the comparison and RMSE
head(comparison)
cat("Root Mean Squared Error (RMSE):", rmse, "\n")

```
````

BREAKOUT

- Splittet Euren Datensatz in Trainings, Validierungs- und Testdatensatz

- Definiert eine lineare Modellgleichung und führt mit Eurem Trainingsdatensatz eine lineare Regression durch. Versucht das adjustierte R^2 des linearen Modells zu maximieren.

- Nutzt das lineare Modell, um eine Vorhersage für den Validierungsdatensatz zu erstellen.

ABRUFEN DES MAPE FÜR DEN TESTDATENSATZ

```r
library(dplyr)
library(readr)
library(httr)

# Dataframe for request must include columns `Datum`, `Warengruppe` und `Umsatz`
predictions <- read_csv("prediction_template.csv")

# name must not be provided; however, each team must upload at least one not
# anonymous prediction
name <- "Gruppe X"

# Execution of the request
r <- POST("https://bakery-sales-mape-tolicqztoq-ey.a.run.app/",
          body = list(name=name, predictions=predictions),
          encode = "json")
# Output of MAPE in Percent
content(r, "parsed", "application/json")
```

AUFGABEN

- Datensatz weiter um zusätzliche Variablen ergänzen, die für die Schätzung des Umsatzes relevant sein könnten.
- Einmal dieses R-Script durchlaufen lassen, um Python (bzw. Miniconda) mit verschiedenen zusätzlichen Funktionspaketen zu installieren.
- Euren Datensatz teilen in einen Trainingsdatensatz vom 01.07.2013 bis 31.03.2019, einem Validierungsdatensatz vom 01.04. bis 07.06.2019 und einem Testdatensatz vom 08.06. bis 30.07.2019
- Modellgleichung aufstellen, die das adjustierte R^2 für Euren Trainingsdatensatz vom 01.07. bis 28.02.2019 maximiert.
- Zum Thema Overfitting dieses Video (9 Minuten) anschauen.
- Euch dieses Video (12 Minuten) zur Einführung in Neuronale Netze an anschauen.